

RETENCION DE EMPLEADOS

Modelo predictivo de renunciaciones voluntarias

"¿Quién va a renunciar en los próximos 12 meses?"

Materia	Economía Empresarial
Grupo	Data o Nada
Integrantes	Knave - Villares - Fiorito - de Bary - Galfione - Gonzalez Minod
Dataset	Retencion de Empleados - Grupo Ser S.A.
Fecha	02 de junio de 2026

1) SELECCIÓN DEL DATASET

Archivo: Retencion_empleados.csv - Fuente: HRIS, encuestas de clima y registros de payroll de GrupoSer S.A.

12.000 registros originales	23 variables (11 num. + 11 cat. + 1 ID)	~30% tasa de renuncia (clase 1)
---------------------------------------	---	---

- Variable objetivo: renuncio_12m - 0 = Permanece | 1 = Renunció en los próximos 12 meses.
- 23 variables: 11 numéricas + 11 categóricas + 1 ID (empleado_id, excluido del modelo).
- Desbalance de clases: aproximadamente 70% permanece / 30% renuncia.
- Post-limpieza: 9.480 registros validos para modelado (21% descartado por calidad).

1.1) CALIDAD DE DATOS

Problemas detectados y tratamiento aplicado:

Columna	Problema detectado	Widget Orange	Tratamiento aplicado
edad	Edades irreales: 5, 6, 7 años (muy bajas) y 140, 150, 160 años (imposibles).	Select Rows	Eliminación de registros fuera del rango laboral válido (18-65 años).
salario_mensual_ars	Valores en \$0 (datos faltantes) y valor tope \$99.999.999 usado como marcador de error.	Select Rows	Eliminación/imputación . Rango válido: \$250.000 a \$3.000.000 ARS.
genero	Multiples formatos: "M", "male", "Masculino", "MASCULINO", "m" / "F", "female", "Femenino", "fema" / "NB", "No_binario", "no binario".	Edit Domain	Estandarizacion a 3 categorias: Masculino, Femenino, No Binario.
nivel_jerarquico	Diferencias de mayusculas, minusculas y espacios ("Senior", "SENIOR", "senior", "Senior ").	Edit Domain	Normalizacion de categorias para unificar los niveles jerarquicos.
horas_extra_promedio_mes	Valores negativos imposibles: -20, -23, -28 horas.	Select Rows	Eliminación de registros inconsistentes.
distancia_oficina_km	Gran cantidad de registros nulos o vacíos.	Impute	Imputación con el promedio general de los datos.
ultimo_feedback_manager	Gran cantidad de registros nulos o vacíos.	Impute	Imputación con el promedio general de los datos.

Resultado final: 9.480 registros válidos conservados de los 12.000 originales (21% descartado).

2) DEFINICIÓN DEL PROBLEMA

Contexto	Problema	Objetivo
GrupoSer S.A. enfrenta alta cantidad de renuncias, generando grandes costos de reemplazo y capacitación.	La empresa no puede identificar con anticipación qué empleados tienen mayor riesgo de renunciar.	Desarrollar un modelo que prediga renuncias voluntarias a 12 meses para implementar acciones de retención oportunas.

Pregunta de negocio: ¿Quién va a renunciar en los próximos 12 meses?

Perder un empleado le cuesta a GrupoSer entre 6 y 9 meses de su salario, considerando el proceso de selección, la curva de aprendizaje del reemplazante y el impacto en los equipos.

Tipo de problema, usuarios y error más costoso

Error mas costoso: Falso Negativo

No detectar a un empleado que finalmente renuncia. Pérdida de oportunidad de actuar. Costo: 6-9 meses de salario.

Usuarios del modelo:

RRHH - People Analytics - HR Business Partners - Lideres de area.

Utilizarán el scoring para priorizar estrategias de retención.

El problema se plantea como clasificación binaria. La variable target renuncio_12m toma valor 0 (permanece) o 1 (renuncio). El análisis prioriza Recall sobre Accuracy, ya que resulta más importante detectar la mayor cantidad posible de empleados en riesgo.

3) ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Hipótesis de Negocio

H1

Los empleados con baja satisfacción laboral tienen mayor probabilidad de renunciar. El gráfico de barras muestra diferencia clara entre niveles. Los empleados con satisfacción baja presentan una tasa de renuncia notablemente superior. Estadísticamente significativo ($\chi^2 = 835.01$, $p = 0.000$). Widget Orange: Bar Chart / Mosaic Display.

	>Sat. Lab = 1 -> 43,5% prob. de renuncia >Sat. Lab = 2 -> 47,09% prob. de renuncia
H2	Los empleados que recibieron feedback negativo de su manager tienen más probabilidad de renunciar. El gráfico de barras muestra una diferencia marcada entre categorías de feedback. Estadísticamente significativo (Chi2 = 351.00, p = 0.000). Widget Orange: Bar Chart. >Feedback Negativo -> 44,85% prob. de renuncia >Feedback Neutro -> menor tasa >Feedback Positivo -> menor tasa
H3	Los empleados con menor antigüedad en la empresa tienden a renunciar más. El histograma muestra que la mayor concentración de renuncias (clase 1) se produce en empleados con 0 a 5 años en la empresa. A mayor antigüedad, menor tasa de renuncia. Widget Orange: Distributions (histograma por clase). >0-5 años de antigüedad -> mayor concentración de renuncias
H4	Los empleados con bajo salario son los que más renuncian. El histograma de salario_mensual_ars muestra que la clase 1 (renuncia) está desproporcionadamente concentrada en los rangos salariales más bajos. A mayor salario, menor proporción de renuncias. Widget Orange: Distributions. >Salarios bajos -> mayor proporción de clase 1 (renuncia)

3) CONCLUSIONES DEL EDA

ok H1 - Confirmada: La satisfacción laboral baja es el predictor más potente. Los niveles 1 y 2 superan el 43-47% de tasa de renuncia.

ok H2 - Confirmada: El feedback negativo del manager es un amplificador significativo del riesgo (44,85%).

ok H3 - Confirmada: Los empleados con menor antigüedad (0-5 años) concentran la mayoría de las renunciaciones.

ok H4 - Confirmada: Los empleados de bajos salarios renuncian más. La relación salario-renuncia es clara en los histogramas.

La señal de renuncia se concentra en variables de bienestar (satisfacción, feedback) y compensación (salario, posición vs. mercado). Las hipótesis orientan directamente el feature engineering y la selección de variables del pipeline.

4) PREPROCESAMIENTO

Pipeline completo aplicado en Orange Data Mining:

Paso	Widget Orange	Descripción y justificación
1. Limpieza categóricas	Edit Domain	Unificación de variantes en genero y nivel_jerarquico a categorías canónicas.
2. Filtrado atípicos	Select Rows	Eliminación de edades imposibles, salarios fuera de rango y horas extra negativas.
3. Imputación de nulos	Impute	Promedio general para distancia_oficina_km y ultimo_feedback_manager.
4. Feature Engineering	Formula (Feature Constructor)	Creación de Ratio_Salarial y Estancamiento. Ver sección 4) Feature Engineering.
5. Eliminación de ID	Select Columns	empleado_id removido (identificador sin poder predictivo).
6. Balance SMOTE	SMOTE	Se generaron observaciones sintéticas de la clase minoritaria (renuncia). Resultado: dataset balanceado 50% permanencia / 50% renuncia, mejorando la capacidad predictiva sobre los casos de renuncia.
7. Partición	Data Sampler	División 80% entrenamiento / 20% prueba. Estratificada y replicable.
8. Evaluación	Test and Score	Cross-Validation estratificada k=10 para comparar los 3 modelos en simultáneo.

4) FEATURE ENGINEERING

Se crearon dos variables derivadas con el widget Fórmula de Orange para capturar señales que las variables originales no expresaban directamente:

Ratio_Salarial	Formula: $\text{salario_mensual_ars} / \text{salario_banda_media_ars}$
Mide la relación entre el salario actual del empleado y el salario promedio del mercado. Un ratio < 1 indica que el empleado está por debajo de la banda de mercado. Captura la competitividad salarial relativa, que las variables originales por separado no expresan.	Variables eliminadas del modelo: empleado_id (identificador sin valor predictivo).

Estancamiento	Formula: $\text{anos_en_puesto} / \text{antigüedad_empresa_anos}$
Mide el grado de permanencia de un empleado en un mismo rol sin avances significativos. Un ratio alto indica empleados que llevan mucho tiempo en la misma posición sin crecer. Complementa la hipótesis de antigüedad con la dimensión de movilidad interna.	Variables eliminadas del modelo: empleado_id (identificador sin valor predictivo).

4) PIPELINE DE ORANGE - WIDGETS UTILIZADOS

El pipeline completo está implementado en el archivo .ows entregado junto a este informe. A continuación se documenta cada widget y su rol en el flujo de trabajo:

Widget	Categoría	Rol en el pipeline
--------	-----------	--------------------

File	Data	Carga del dataset Retencion_empleados.csv
Feature Statistics	Data	Exploración inicial: nulos, outliers y distribuciones
Edit Domain	Data	Unificación de variantes en género y nivel_jerarquico
Select Rows	Data	Filtrado de edades, salarios y horas extra fuera de rango
Impute	Data	Imputación con promedio general: distancia_oficina_km y ultimo_feedback_manager
Formula	Data	Creación de Ratio_Salarial y Estancamiento
Select Columns	Data	Eliminación de empleado_id
SMOTE	Data	Balanceo de clases 50/50 sobre el set de entrenamiento
Distributions	Visualize	EDA: distribución de variables y comparacion por clase
Bar Chart	Visualize	EDA: H1 (satisfacción) y H2 (feedback) vs renuncio_12m
Mosaic Display	Visualize	EDA: interacción entre satisfacción y feedback
Data Sampler	Data	Particion estratificada 80/20 para train/test
Random Forest	Model	Modelo ganador. 3 modelos evaluados en simultáneo.
Logistic Regression	Model	Modelo interpretable. Ridge L2, C=1.
Naive Bayes	Model	Modelo probabilistico benchmark.
Test and Score	Evaluate	Cross-Validation k=10 estratificada. Compara los 3 modelos.
Confusion Matrix	Evaluate	Análisis de errores del modelo ganador (RF).
ROC Analysis	Evaluate	Curva ROC. AUC 0,803 del Random Forest.
Nomogram	Model	Peso de cada variable en Logistic Regression (interpretación).

5) MODELOS EVALUADOS

Se compararon tres algoritmos de clasificación usando el mismo pipeline, el mismo dataset balanceado (SMOTE) y la misma partición 80/20. Se usó Cross-Validation k=10 para una evaluación robusta y estratificada.

Modelo	Descripcion	Rol en el analisis
Random Forest (*)	Ensamble de múltiples árboles de decisión. Captura relaciones complejas.	Modelo ganador. Mayor AUC, Recall, F1 y MCC.
Logistic Regression	Clasificación lineal interpretable. Ridge L2, C=1.	Modelo interpretable. Permite explicar variables via Nomogram.
Naive Bayes	Clasificador probabilístico. Asume independencia entre predictores.	Benchmark de referencia. Base comparativa.

(*) **Modelo ganador seleccionado.**

6) METODOLOGIA DE EVALUACION

Particion y Cross-Validation

Se utilizó el widget Data Sampler de Orange para dividir el dataset en 80% entrenamiento y 20% prueba (estratificado). El widget Test and Score evaluó los 3 modelos con Cross-Validation estratificada k=10: el dataset se divide en 10 partes, el modelo entrena 10 veces usando 9 partes y evalúa en 1. Los resultados se promedian, dando un estimador más robusto que un split simple.

Por que priorizamos Recall?

Falso Negativo - ERROR MAS COSTOSO
No detectar a un empleado que finalmente renuncia. Costo: 6-9 meses de salario. Es el indicador más importante para este caso.

Falso Positivo - Error menor
Predecir renuncia cuando no renuncia. Acciones de retención innecesarias. Costo recuperable.

Metricas utilizadas

- AUC - capacidad de separar las dos clases. +0,80 = muy bueno para este tipo de problema.
- CA (Accuracy) - porcentaje global de aciertos. Referencia general.
- Recall - de todos los que renuncian, ¿cuántos detectó el modelo? Métrica decisora principal.
- Precisión - de los marcados como riesgo, ¿cuántos realmente renuncian?
- F1 - balance entre Recall y Precision.
- MCC - métrica de balance entre clases. La más robusta para datasets con desbalance.

ROC Analysis

El widget ROC Analysis de Orange confirma la capacidad discriminativa del Random Forest (AUC = 0,803): el modelo distingue correctamente entre empleados que renunciaran y los que permanecerán en el 80,3% de los casos, muy por encima del azar (AUC = 0,5). La curva ROC permite además evaluar distintos umbrales de decisión según el trade-off costo/beneficio requerido por el área de RRHH.

6) RESULTADOS COMPARATIVOS

Evaluación sobre target = 1 (clase renuncia). Cross-Validation k=10, dataset balanceado con SMOTE.

Modelo	AUC	CA	F1	Precision	Recall	MCC
Random Forest (*)	0,803	0,729	0,735	0,728	0,743	0,458
Naive Bayes	0,748	0,681	0,690	0,680	0,699	0,363
Logistic Regression	0,742	0,683	0,692	0,682	0,702	0,366

Random Forest lidera en todas las métricas. Obtiene el mejor AUC (0,803), el mejor Recall (0,743) - detecta el 74,3% de las futuras renunciaciones - y el mejor equilibrio F1 (0,735). Es el modelo más robusto para este caso de uso.

EL CAMPEÓN: RANDOM FOREST

0,803 AUC	0,743 Recall	0,728 Precision	0,735 F1
---------------------	------------------------	---------------------------	--------------------

Justificación de la elección

- Mejor AUC (0,803) - distingue correctamente entre empleados que renunciaran y los que no en el 80,3% de los casos.
- Mejor Recall (0,743) - detecta el 74,3% de las futuras renunciaciones. Es el indicador más importante para el caso.
- Mejor F1 (0,735) - mejor equilibrio entre detección de renunciaciones y evitar falsas alarmas.
- Mejor MCC (0,458) - balance superior entre clases en un dataset con desbalance 70/30.
- Random Forest captura relaciones complejas y no lineales entre variables, superando al modelo lineal (LR: AUC 0,742).

- El widget Feature Importance de Orange permite extraer y comunicar las variables más relevantes.

MATRIZ DE CONFUSIÓN Y ROC

Conjunto de prueba (3.283 registros) - Random Forest

	Pred: Permanece (0)	Pred: Renuncia (1)
Real: Permanece (0)	1.242 Verdaderos Negativos	397 Falsos Positivos
Real: Renuncia (1)	438 Falsos Negativos - Error mas costoso	1.206 Verdaderos Positivos

1.206 Verdaderos Positivos: Empleados que iban a renunciar y el modelo detectó correctamente. Candidatos a acciones de retención.

1.242 Verdaderos Negativos: Empleados que permanecen, correctamente clasificados como estables.

438 Falsos Negativos: Empleados que renunciaron y no fueron detectados. El error más costoso del modelo.

397 Falsos Positivos: Acciones de retención innecesarias. Costo menor, recuperable.

Curva ROC - AUC 0,803

El widget ROC Analysis de Orange confirma que el Random Forest discrimina muy bien por encima del azar (AUC = 0,5). Un AUC de 0,803 indica que en el 80,3% de los casos el modelo asigna mayor probabilidad de renuncia a quien efectivamente renuncia. Para el contexto de retención de talento, este valor es sólido y operacionalmente útil.

IMPACTO EN EL NEGOCIO

Simulación sobre el conjunto de prueba (3.283 registros):

3.283 empleados del periodo	1.603 alertas generadas (49%)	1.206 renuncias detectadas	73,4% del riesgo real capturado
---------------------------------------	---	--------------------------------------	---

Con el modelo activo, RRHH puede detectar el 73,4% de las renunciaciones (1.206 de 1.644 empleados que realmente renuncian en el periodo de prueba), interviniendo proactivamente antes de que sea tarde. Solo 438 renunciaciones escapan al modelo (falsos negativos).

Frente al proceso actual (100% reactivo, 0% predictivo), esto representa una reducción sustancial en los costos de rotación y un uso más eficiente de los recursos de RRHH.

7) INTERPRETACION - FEATURE IMPORTANCE Y NOMOGRAM

Se utilizaron dos widgets de Orange para interpretar el modelo: Feature Importance (Random Forest) y Nomogram (Logistic Regression, como modelo complementario interpretable).

Variables con mayor impacto en la probabilidad de renuncia

Ranking	Variable	Dirección del efecto
#1	Salario mensual (salario_mensual_ars)	Salarios bajos -> mayor probabilidad de renuncia. La variable con mayor impacto en el modelo.
#2	Posicion salarial vs. mercado (Ratio_Salarial)	Empleados por debajo del benchmark de mercado -> mayor propensión a renunciar.
#3	Satisfacción laboral	Baja satisfacción -> incremento marcado del riesgo. Confirma H1 del EDA.
#4	Antigüedad en la empresa (antigüedad_empresa_anos)	Menor antigüedad -> mayor riesgo de renuncia. Confirma H3 del EDA.
#5	Nivel educativo (impacto menor, pero estratégicamente relevante)	Mayor formación -> más oportunidades externas -> mayor propensión a renunciar. Hallazgo sorprendente.

Hallazgo sorprendente: nivel educativo

El nivel educativo aparece como una variable relevante en el modelo. Esto sugiere que empleados con mayor formación podrían tener más oportunidades laborales externas y, por lo tanto, mayor propensión a renunciar. Es un hallazgo contra-intuitivo: se esperaría que mayor formación implique mayor costo de salida, pero el mercado laboral le ofrece más opciones a estos perfiles, reduciendo ese costo.

7) VALIDACIÓN DE HIPÓTESIS POR EL MODELO

Las hipótesis del EDA fueron cotejadas contra el Feature Importance del Random Forest:

Hipotesis	Estado EDA	Confirmacion por modelo	Posición en Feature Importance
H1 - Baja satisfacción laboral	Confirmada	Confirmada - satisfacción en el top 3 del modelo	#3
H2 - Feedback negativo del manager	Confirmada en EDA	No aparece en top 5 del Feature Importance. Validada por el EDA pero menor peso en el modelo final.	—
H3 - Menor antigüedad	Confirmada	Confirmada - antigüedad en el top 4 del modelo	#4
H4 - Bajo salario	Confirmada	Confirmada - salario mensual es la variable #1 del modelo	#1

H1, H3 y H4 fueron confirmadas tanto en el EDA como por el Feature Importance del modelo. H2 (feedback) fue validada en el análisis exploratorio pero no emerge entre las variables más determinantes del Random Forest. El nivel educativo fue el hallazgo sorprendente del modelo.

CONCLUSIONES Y LECCIONES APRENDIDAS

Conclusiones

- > **Modelo operativo:** Random Forest con AUC 0,803 y Recall 0,743. Detecta el 73,4% de las renunciaciones futuras (1.206 de 1.644 casos reales).
- > **SMOTE fue determinante:** El balanceo 50/50 permitió que el modelo aprendiera mejor la clase minoritaria (renuncia), mejorando significativamente el Recall.
- > **El salario es el predictor #1:** salario_mensual_ars y la posición salarial vs. mercado son las variables de mayor impacto, confirmando H4.
- > **Las relaciones son no lineales:** Random Forest superó a Logistic Regression (AUC 0,803 vs 0,742), lo que indica que las relaciones entre variables y renuncia tienen componentes no lineales.

Lecciones Aprendidas

- La limpieza de datos fue la etapa más crítica. Las variantes en género (más de 15 formas) y los valores tope en salario habían distorsionado completamente el modelo sin corrección previa.

- SMOTE mejoró el Recall de forma notable. Al balancear el dataset antes del entrenamiento, el modelo dejó de ignorar la clase minoritaria y aprendió patrones reales de renuncia.
- El Feature Engineering fue una decisión clave. Ratio_Salarial y Estancamiento capturan señales que las variables originales no podían expresar por separado.
- La interpretabilidad tiene valor de negocio. El Nomogram de Logistic Regression, aunque no sea el modelo ganador, permite al equipo de RRHH explicar el riesgo a cada manager.
- El nivel educativo fue una sorpresa. Un predictor no anticipado en el EDA emergió como relevante en el modelo, demostrando el valor de dejar que los datos hablen.

DE LOS DATOS A LA ACCIÓN: 3 PILARES ESTRATÉGICOS

Una estrategia focalizada en compensación, satisfacción y desarrollo profesional permitirá reducir la rotación y los costos asociados al reemplazo de personal.

P1

Compensación Inteligente: Revisión inmediata de competitividad salarial. Ejecutar ajustes precisos en empleados clave que se encuentran por debajo del benchmark de mercado. El salario mensual es la variable #1 del modelo: actuar sobre él tiene el mayor impacto posible en retención.

P2

Monitoreo de Clima Activo: Implementar encuestas de pulso periódicas y diseñar planes de contención inmediatos sobre equipos que muestren bajos niveles de satisfacción. La satisfacción laboral es el tercer predictor más importante del modelo.

P3

Blindaje de Talento Crítico: Diseñar planes de carrera estructurados. Focalizar agresivamente en empleados con alta formación y perfiles críticos para neutralizar el riesgo de fuga. El nivel educativo emergió como predictor estratégicamente relevante: los perfiles más cualificados tienen más oportunidades externas y mayor propensión a renunciar sin desarrollo interno.

Próximos pasos: pipeline productivo en Python (SMOTE solo sobre train) - tuning de hiperparametros del Random Forest - calibración del umbral de decisión según costo/beneficio del negocio - integración con HRIS para scoring automático mensual.